

# **ANÁLISIS EXPLORATORIO DEL DATASET**


**Pablo Noriega Vázquez**

**15/02/2026**

## ÍNDICE

|                                                              |    |
|--------------------------------------------------------------|----|
| 1. DISTRIBUCIÓN DE ACCIONES RECOMENDADAS.....                | 3  |
| 2. MOTIVOS DE RECOMENDACIÓN.....                             | 4  |
| 3. DISTRIBUCIÓN DE FUENTES DE DETECCIÓN .....                | 5  |
| 4. EXPOSICIÓN DE LOS ACTIVOS .....                           | 6  |
| 5. REPUTACIÓN DE IP.....                                     | 7  |
| 6. ROL DE USUARIO.....                                       | 8  |
| 7. TOLERANCIA AL DOWNTIME.....                               | 9  |
| 8. PAÍS DE ORIGEN .....                                      | 10 |
| 9. HORARIO LABORAL .....                                     | 11 |
| 10. ANOMALÍA GEOGRÁFICA .....                                | 12 |
| 11. REINCIDENCIA.....                                        | 13 |
| 12. CUENTA PRIVILEGIADA .....                                | 14 |
| 13. SOPORTE DE AISLAMIENTO .....                             | 15 |
| 14. DISTRIBUCIÓN DE LA CONFIANZA DE DETECCIÓN .....          | 16 |
| 15. DISTRIBUCIÓN DEL NÚMERO DE EVENTOS .....                 | 17 |
| 16. INCIDENTES EN 30 DÍAS PREVIOS .....                      | 18 |
| 17. VENTANA TEMPORAL DE CORRELACIÓN .....                    | 19 |
| 18. PROBABILIDAD DE ACCIÓN SEGÚN FASE DEL ATAQUE.....        | 20 |
| 19. PROBABILIDAD DE ACCIÓN SEGÚN CRITICIDAD DEL ACTIVO ..... | 21 |
| 20. BOXPLOT DE CONFIDENCE POR ACCIÓN RECOMENDADA .....       | 22 |
| 21. BOXPLOT DE SEVERITY POR ACCIÓN RECOMENDADA .....         | 23 |

## 1. DISTRIBUCIÓN DE ACCIONES RECOMENDADAS




El gráfico muestra la frecuencia de cada acción recomendada en el dataset sintético. Las acciones más frecuentes son `investigate` y `block_ip`, lo cual refleja un comportamiento realista de los centros de operaciones de seguridad (SOC).

En entornos reales, muchas alertas requieren validación adicional antes de aplicar medidas disruptivas, por lo que la acción `investigate` aparece como la más común. Por otro lado, `block_ip` es una medida de contención habitual ante actividades sospechosas de red como escaneos o intentos de acceso.

Las acciones más invasivas, como `isolate_host`, `disable_account` o `reset_credentials`, aparecen con menor frecuencia. Esta distribución es coherente con la práctica operativa, donde este tipo de acciones se reservan para incidentes más graves debido a su posible impacto operativo.

La distribución obtenida indica que el dataset reproduce de forma razonable la jerarquía de respuestas típica en sistemas de respuesta a incidentes.

## 2. MOTIVOS DE RECOMENDACIÓN



El gráfico muestra los motivos que justifican la acción recomendada. En el dataset sintético se observa un claro predominio de `playbook_base`, que representa aproximadamente el 64% de los registros.


Este comportamiento es intencional y refleja cómo operan muchos sistemas de respuesta automática en entornos SOC, donde las decisiones iniciales se basan en playbooks predefinidos que establecen acciones estándar ante determinados tipos de alertas.

El segundo motivo más frecuente es `repeat_offender`, lo que simula escenarios donde una entidad (por ejemplo, una dirección IP o usuario) ha generado incidentes previamente. En estos casos es habitual que las respuestas sean más restrictivas.

El resto de motivos aparecen con menor frecuencia para representar situaciones específicas de seguridad, como anomalías geográficas, riesgo asociado a cuentas privilegiadas o señales de alta confianza.

Esta distribución permite que el dataset simule un sistema híbrido de decisión basado en reglas y contexto operativo.

### 3. DISTRIBUCIÓN DE FUENTES DE DETECCIÓN




El gráfico de detection\_source muestra que las principales fuentes de alertas son IDS, Firewall y SIEM.

Esto refleja la arquitectura típica de monitorización en seguridad, donde los sistemas de detección de intrusiones y los dispositivos de red generan una gran cantidad de alertas relacionadas con tráfico sospechoso o intentos de acceso.

Otras fuentes como EDR, NDR o Email Gateway también están representadas, aunque con menor frecuencia, para simular diferentes capas de detección en un entorno corporativo.

La distribución se diseñó de forma que refleje un ecosistema de detección multicapa, similar al que se encuentra en infraestructuras reales.

## 4. EXPOSICIÓN DE LOS ACTIVOS




El gráfico muestra que la mayoría de los activos del dataset son internos, mientras que una proporción menor corresponde a activos expuestos a Internet.

Esta distribución se diseñó para reflejar que, aunque los ataques suelen originarse desde el exterior, una parte importante de las alertas detectadas en organizaciones reales corresponde a actividad dentro de la red corporativa, incluyendo tráfico interno o movimientos laterales tras un compromiso inicial.

Por tanto, la proporción utilizada permite simular escenarios tanto de ataques externos como de actividad interna sospechosa.

## 5. REPUTACIÓN DE IP




La mayoría de las direcciones IP aparecen clasificadas como good, seguidas por suspicious y finalmente bad.

Esta distribución fue diseñada para reflejar una situación realista donde muchas actividades sospechosas no provienen necesariamente de IPs previamente catalogadas como maliciosas. En entornos reales es frecuente que los atacantes utilicen infraestructuras comprometidas o direcciones que aún no están incluidas en listas de reputación.

Por tanto, la variable ip\_reputation aporta contexto adicional al proceso de decisión sin determinar completamente la respuesta.

## 6. ROL DE USUARIO




El dataset presenta una mayoría de usuarios estándar, con menor presencia de administradores y cuentas de servicio.

Esto reproduce la distribución típica de cuentas en organizaciones reales, donde los usuarios estándar son mucho más numerosos. Sin embargo, la inclusión de cuentas privilegiadas permite simular incidentes de mayor riesgo, ya que estas cuentas tienen acceso a sistemas críticos.



## 7. TOLERANCIA AL DOWNTIME




El gráfico muestra tres niveles de tolerancia al downtime: alta, media y baja. La mayor parte de los activos presenta tolerancia media o baja.

Esta variable se incluyó para simular el impacto operativo que pueden tener determinadas acciones de respuesta. En sistemas críticos, por ejemplo, aislar un host o deshabilitar un servicio puede no ser viable sin análisis previo.

Por tanto, esta característica introduce restricciones operativas realistas en la toma de decisiones.

## 8. PAÍS DE ORIGEN




El país de origen muestra un predominio de tráfico interno, acompañado por múltiples países externos con menor frecuencia.

Esta distribución se diseñó para reflejar que, en muchos casos, la actividad sospechosa detectada proviene de sistemas dentro de la propia red corporativa, mientras que el tráfico externo puede originarse desde múltiples ubicaciones geográficas.

La inclusión de varios países permite simular variabilidad geográfica en las conexiones.


## 9. HORARIO LABORAL



La mayoría de los eventos ocurre fuera del horario laboral. Esta decisión de diseño se basa en la observación de que muchos ataques automatizados se producen en momentos de menor actividad humana, lo que reduce la probabilidad de detección inmediata.


Incluir esta característica permite simular un contexto temporal relevante para la evaluación de incidentes.

## 10. ANOMALÍA GEOGRÁFICA




Solo una pequeña proporción de eventos presenta anomalías geográficas. Esto refleja que este tipo de eventos suele ser relativamente poco frecuente, aunque cuando aparece puede representar un indicador importante de actividad sospechosa.

## 11. REINCIDENCIA




Una parte del dataset corresponde a entidades reincidentes. Esta variable se incluyó para simular situaciones donde una misma IP o usuario genera incidentes repetidos, lo cual suele influir en la severidad de la respuesta.

## 12. CUENTA PRIVILEGIADA



El dataset incluye una proporción moderada de incidentes relacionados con cuentas privilegiadas. Esta variable permite simular escenarios de mayor riesgo, ya que los accesos asociados a cuentas con privilegios elevados suelen tener un impacto potencial mayor.


### 13. SOPORTE DE AISLAMIENTO



La mayoría de los activos permite aislamiento. Esto refleja que muchas infraestructuras modernas incluyen mecanismos de contención automática, como aislamiento de endpoints o segmentación de red.

No obstante, la existencia de casos donde el aislamiento no está disponible permite introducir restricciones técnicas en el proceso de decisión.

## 14. DISTRIBUCIÓN DE LA CONFIANZA DE DETECCIÓN



Esta variable representa el nivel de confianza del sistema de detección en que la alerta corresponde a una actividad maliciosa.


El gráfico indica que la mayoría de alertas del dataset tienen una confianza moderada o alta, lo cual es coherente con el funcionamiento de sistemas de detección en entornos SOC. En sistemas reales, muchas alertas con baja confianza suelen filtrarse o clasificarse como ruido antes de formar parte de un incidente.

El hecho de que la media esté cerca de 0.7 sugiere que el dataset simula incidentes donde existe una probabilidad significativa de actividad maliciosa, aunque no necesariamente certeza absoluta. Esto permite modelar situaciones donde el sistema debe decidir entre investigar, bloquear o escalar el incidente en función de la información disponible.

En el contexto del modelo de recomendación, esta variable actúa como un indicador de fiabilidad de la detección, lo que puede influir en la severidad de la respuesta recomendada.



## 15. DISTRIBUCIÓN DEL NÚMERO DE EVENTOS



La variable `event_count` representa el número de eventos individuales correlacionados dentro de un mismo incidente.


Este gráfico refleja un comportamiento típico de sistemas SIEM o plataformas de detección, donde múltiples eventos relacionados se agrupan en un único incidente.

Un mayor número de eventos puede indicar:

- actividad persistente
- múltiples intentos de acceso
- propagación dentro de la red
- correlación de alertas provenientes de diferentes sistemas

En el dataset sintético, esta variable se diseñó para simular incidentes de diferente complejidad, desde eventos aislados hasta incidentes más extensos.

## 16. INCIDENTES EN 30 DÍAS PREVIOS




Esta variable mide cuántos incidentes se han asociado previamente a la misma entidad (por ejemplo IP o usuario) en los últimos 30 días.

Esto indica que la mayoría de entidades no presenta incidentes previos recientes, pero existe un subconjunto que sí muestra actividad repetida.

La inclusión de esta variable permite simular escenarios donde el sistema puede detectar patrones de comportamiento recurrente, lo que en la práctica suele influir en la decisión de aplicar medidas más restrictivas.

Por ejemplo, una entidad con múltiples incidentes recientes podría justificar acciones como el bloqueo de IP o la deshabilitación de cuentas.

## 17. VENTANA TEMPORAL DE CORRELACIÓN



La variable `time_window_minutes` representa la ventana temporal utilizada para agrupar eventos en un incidente.


Esto significa que la mayoría de incidentes se construyen a partir de eventos que ocurren dentro de intervalos relativamente cortos.

En entornos reales, este tipo de ventanas temporales se utilizan para detectar patrones como:

- escaneos de red
- múltiples intentos de autenticación
- actividad automatizada

La inclusión de esta variable permite simular dinámicas temporales de ataque, lo cual aporta realismo al dataset.

## 18. PROBABILIDAD DE ACCIÓN SEGÚN FASE DEL ATAQUE



El análisis de la probabilidad condicional entre la fase del ataque (*attack\_phase*) y la acción recomendada permite observar cómo evoluciona la respuesta del sistema a medida que avanza el ataque.

En la fase de reconocimiento, donde el atacante recopila información mediante escaneos o sondas, predominan acciones como el bloqueo de la dirección IP o la investigación adicional. Este comportamiento reproduce una estrategia defensiva habitual, donde el objetivo principal es detener o analizar la actividad antes de que el atacante consiga acceso al sistema.


Cuando el ataque entra en la fase de acceso inicial, aumenta la presencia de acciones como la investigación o el restablecimiento de credenciales. Esto refleja situaciones donde existe sospecha de compromiso de cuentas, lo que puede requerir intervención sobre las credenciales afectadas.

En la fase de ejecución de código malicioso aparecen con mayor frecuencia acciones más contundentes, como el aislamiento del host o el escalado del incidente. Esto es coherente con el hecho de que la ejecución de malware suele indicar que el atacante ya ha logrado penetrar en el sistema.

En fases posteriores como el movimiento lateral, el sistema recomienda principalmente escalar el incidente para su gestión por parte de analistas especializados. Finalmente, en la fase de exfiltración la acción dominante es el escalado, ya que esta fase implica un riesgo directo de pérdida de información sensible.

En conjunto, esta relación reproduce una lógica de defensa progresiva en la que las respuestas se vuelven más severas conforme el ataque avanza en la cadena de compromiso.

## 19. PROBABILIDAD DE ACCIÓN SEGÚN CRITICIDAD DEL ACTIVO




La variable `asset_criticality` describe la importancia del activo afectado dentro de la infraestructura. El análisis muestra que cuando los activos tienen alta criticidad aumentan las acciones de bloqueo y escalado del incidente.

Este comportamiento refleja una política de seguridad habitual: cuanto más crítico es el sistema afectado, mayor es la prioridad de la respuesta y menor la tolerancia al riesgo.

En activos de criticidad media, las acciones se distribuyen principalmente entre investigación y bloqueo de IP. En estos casos el sistema busca confirmar la naturaleza del incidente antes de aplicar medidas más agresivas.

Por el contrario, en activos de baja criticidad aparecen con mayor frecuencia acciones como ignorar o investigar la alerta. Esto simula escenarios donde el impacto potencial del incidente es menor y se permite un mayor margen de análisis antes de intervenir.

## 20. BOXPLOT DE CONFIDENCE POR ACCIÓN RECOMENDADA




El boxplot que relaciona la variable confidence con las acciones recomendadas permite analizar si las decisiones más severas se asocian a detecciones más fiables.

En un sistema de respuesta a incidentes es razonable que acciones como aislar un host o escalar un incidente se produzcan principalmente cuando el sistema de detección tiene un alto grado de confianza en la alerta. Por el contrario, acciones como investigar o ignorar pueden aparecer en situaciones donde la evidencia es menos concluyente.

Este tipo de visualización permite comprobar que la severidad de la respuesta mantiene una relación coherente con el nivel de confianza de la detección.

## 21. BOXPLOT DE SEVERITY POR ACCIÓN RECOMENDADA



La variable severity representa la gravedad estimada del incidente. El boxplot que relaciona esta variable con las acciones recomendadas permite observar si existe coherencia entre la gravedad del incidente y la respuesta aplicada.

En un escenario realista, los incidentes con mayor severidad deberían asociarse con acciones más restrictivas, como el aislamiento de sistemas o el escalado del incidente. Por el contrario, incidentes de severidad baja pueden gestionarse mediante investigación adicional o incluso ignorarse si se considera que el riesgo es limitado.

Este análisis ayuda a validar que el dataset mantiene una relación lógica entre la gravedad del incidente y la respuesta sugerida.