

**SOC INTELIGENTE Y ADAPTATIVO:
AUTOMATIZACIÓN E INTELIGENCIA ARTIFICIAL
PARA LA NUEVA GENERACIÓN DE
CIBERDEFENSA**

Pablo Noriega Vázquez

15/03/2026

ÍNDICE

1. RESUMEN EJECUTIVO	2
2. INTRODUCCIÓN	3
3. APORTACIONES	4
4. DEFINICIÓN.....	5
4.1 ARQUITECTURA DEL SISTEMA	5
4.2 AUTOMATIZACIÓN Y FLUJO OPERATIVO DEL SOC.....	5
4.3 ASISTENCIA MEDIANTE INTELIGENCIA ARTIFICIAL.....	6
4.4 APRENDIZAJE CONTINUO Y ENTRENAMIENTO	7
4.5 VALOR DIFERENCIAL DE LA PROPUESTA	7
5. DESARROLLO	8
5.1 CONSTRUCCIÓN DEL DATASET Y ENTRENAMIENTO DEL MODELO	8
5.2 SELECCIÓN DEL MODELO DE IA GENERATIVA	8
5.3 CONSTRUCCIÓN DE LA ARQUITECTURA DEL SISTEMA	9
5.4 AUTOMATIZACIÓN DEL FLUJO OPERATIVO.....	9
5.5 INTEGRACIÓN DE INTELIGENCIA ARTIFICIAL EN LOS FLUJOS.....	9
6. EVALUACIÓN.	10
6.1 EVALUACIÓN DEL MODELO DE MACHINE LEARNING	10
6.2 EVALUACIÓN DE LA AUTOMATIZACIÓN DEL FLUJO OPERATIVO....	10
6.3 EVALUACIÓN DEL FLUJO DE APRENDIZAJE	11
6.4 COMPARACIÓN CON SOLUCIONES DEL MERCADO.....	11
7. CONCLUSIÓN	12
8. BIBLIOGRAFIA	13
9. ANEXOS	14
9.1 CÓDIGO FUENTE DE LA SOLUCIÓN	14
9.1 DIAGRAMA DE ARQUITECTURA DE LA SOLUCIÓN	14
9.2 ESTRUCTURA DE LA BASE DE DATOS.....	15
9.3 CLIENTE SOC.....	16
9.4 RESULTADOS DEL ENTRENAMIENTO DEL MODELO	18

1. RESUMEN EJECUTIVO

La creciente sofisticación y volumen de las amenazas de ciberseguridad ha incrementado significativamente la carga operativa de los Centros de Operaciones de Seguridad (SOC).

Estos entornos deben gestionar un elevado número de alertas procedentes de múltiples fuentes, lo que genera problemas como fatiga del analista, tiempos de respuesta elevados y dificultades para mantener niveles de servicio adecuados. En este contexto, la automatización y el uso de técnicas de inteligencia artificial se han convertido en herramientas clave para mejorar la eficiencia operativa de los SOC.

Este trabajo propone el diseño e implementación de un SOC parcialmente gestionado mediante inteligencia artificial, cuyo objetivo es optimizar la gestión de alertas, mejorar la asignación de recursos y facilitar la toma de decisiones de los analistas.

Para ello, se ha desarrollado un sistema que integra automatización mediante n8n y un modelo de Machine Learning basado en Random Forest, entrenado con un dataset propio generado a partir de escenarios de gestión de incidentes de seguridad.

El sistema permite gestionar el ciclo completo de vida de una alerta. Cuando se genera una alerta, se activa un flujo automatizado que registra el incidente, lo muestra en el panel del SOC y asigna la alerta a un operador teniendo en cuenta variables como su especialización, turno y disponibilidad. Posteriormente, el sistema utiliza el modelo de inteligencia artificial entrenado para sugerir la acción más adecuada para resolver el incidente.

El SOC desarrollado incorpora además un panel de monitorización que permite visualizar el estado general del centro de operaciones, incluyendo indicadores como el estado de las alertas, el nivel de ocupación de los operadores, el estado de los recursos críticos y métricas de rendimiento relacionadas con la gestión de incidentes y los tiempos de respuesta del sistema.

El sistema incluye un módulo de entrenamiento para analistas en el que se presentan alertas simuladas que deben resolver. Sus decisiones se comparan con las recomendaciones del modelo para evaluar su desempeño y el sistema registra métricas como el porcentaje de aciertos y errores. Cuando la respuesta no coincide con la recomendación del modelo, se muestra una explicación de la acción correcta.

Este trabajo demuestra cómo la integración de inteligencia artificial, automatización y monitorización avanzada puede contribuir a la evolución de los SOC hacia entornos más eficientes y adaptativos.

2. INTRODUCCIÓN

Los Centros de Operaciones de Seguridad (Security Operations Centers, SOC) son un elemento fundamental en la protección de las infraestructuras tecnológicas de las organizaciones. Su función principal es monitorizar, detectar, analizar y responder a incidentes que puedan comprometer la confidencialidad, integridad o disponibilidad de los sistemas de información.

Sin embargo, el crecimiento del número de eventos de seguridad generados por sistemas como SIEM, IDS/IPS, EDR y otras herramientas de monitorización supone un reto para los SOC. Los analistas deben gestionar grandes volúmenes de alertas, muchas de ellas falsos positivos o incidentes de baja criticidad, lo que genera el fenómeno conocido como alert fatigue, que reduce la eficiencia de los equipos y aumenta el riesgo de que incidentes relevantes pasen desapercibidos.

Para afrontar este problema, muchas organizaciones han adoptado tecnologías de automatización y orquestación de seguridad (SOAR), que permiten automatizar tareas repetitivas y mejorar la coordinación entre herramientas y analistas. Plataformas como Splunk SOAR, Palo Alto Cortex XSOAR o IBM Resilient permiten automatizar flujos de respuesta a incidentes, reduciendo tiempos de reacción y liberando a los analistas para tareas de mayor valor.

Paralelamente, el uso de técnicas de Machine Learning e inteligencia artificial en ciberseguridad ha crecido notablemente (Buczak, 2016) (Xin, 2018), aplicándose modelos supervisados como Random Forest o redes neuronales (Shaukat, 2020) en tareas como detección de intrusiones, clasificación de alertas y priorización de incidentes.

Diversos trabajos han explorado el uso de inteligencia artificial para optimizar la gestión de incidentes en SOC, aunque muchas propuestas se centran principalmente en la detección o clasificación de alertas, dejando en segundo plano la gestión de recursos humanos, el entrenamiento de analistas o la adaptación continua de los modelos.

En este contexto, este Trabajo de Fin de Máster propone el diseño y desarrollo de un SOC autogestionado apoyado por inteligencia artificial que integra automatización, recomendación de acciones y aprendizaje continuo dentro del flujo operativo del centro de seguridad. El sistema aborda aspectos clave de la operación de un SOC:

- Asignación de alertas y recomendación de acciones usando IA.
- Monitorización del rendimiento mediante indicadores SLA.
- Entrenamiento de analistas mediante simulación de incidentes.
- Reentrenamiento del modelo a partir de la experiencia real del SOC.

Mediante la integración de estos componentes se busca demostrar que la inteligencia artificial puede utilizarse no solo para detectar amenazas (Apruzzese, 2023), sino también para optimizar la gestión operativa de un SOC y mejorar la colaboración entre analistas y sistemas automatizados.

3. APORTACIONES

El objetivo de este proyecto es desarrollar una solución que vaya más allá de las herramientas tradicionales de gestión y monitorización de un SOC. En lugar de limitarse a visualizar y gestionar alertas, se busca proporcionar a los operadores apoyo en la toma de decisiones mediante el uso de inteligencia artificial y flujos automatizados.

El valor de la propuesta se refleja en las siguientes aportaciones:

- Diseño y desarrollo de un prototipo de SOC parcialmente autogestionado mediante inteligencia artificial, orientado a mejorar la gestión de alertas y apoyar la toma de decisiones de los analistas.
- Integración de automatización y modelos de Machine Learning para la asignación inteligente de alertas y la recomendación de acciones ante incidentes de seguridad.
- Implementación de mecanismos de monitorización del rendimiento del SOC, incluyendo indicadores operativos y métricas SLA.
- Desarrollo de un módulo de entrenamiento para analistas, basado en simulación de incidentes y evaluación de las respuestas.
- Capacidad de reentrenamiento del modelo de inteligencia artificial a partir de la experiencia y decisiones reales tomadas por los operadores del SOC.

4. DEFINICIÓN.

4.1 ARQUITECTURA DEL SISTEMA

La solución propuesta se basa en una arquitectura modular implementada mediante contenedores Docker, como se muestra en la Figura 1, lo que permite desplegar y gestionar de forma independiente los distintos componentes del sistema. Este enfoque facilita el mantenimiento, la escalabilidad y la evolución de la plataforma, además de mejorar la reproducibilidad del entorno y permitir la incorporación de nuevos servicios sin afectar al funcionamiento global del sistema.

Dentro de esta arquitectura se integran varios servicios que cooperan entre sí para gestionar el ciclo completo de vida de las alertas de seguridad:

- API SOC, encargada de gestionar alertas, incidentes y operadores.
- Cliente SOC, interfaz que permite la interacción del usuario con el sistema.
- API de inteligencia artificial, responsable del entrenamiento y ejecución del modelo de Machine Learning.
- Base de datos, donde se almacenan alertas, decisiones de los analistas y datasets de entrenamiento.
- N8N, encargado de orquestar los flujos operativos.
- Simulador de alertas, utilizado para generar escenarios de entrenamiento.

La combinación de estos componentes permite construir un entorno operativo en el que la gestión de incidentes, el análisis asistido por inteligencia artificial y el aprendizaje del sistema se integran dentro de una misma plataforma.

4.2 AUTOMATIZACIÓN Y FLUJO OPERATIVO DEL SOC

El sistema incorpora n8n como motor de automatización, encargado de orquestar los flujos de trabajo. Este componente permite automatizar diversas tareas dentro del ciclo de vida de un incidente, reduciendo la carga operativa de los analistas y mejorando la eficiencia del proceso de gestión.

Cuando se genera una alerta, el sistema activa automáticamente un flujo de trabajo que realiza las siguientes acciones:

1. Registro de la alerta en el sistema.
2. Asignación del incidente a un operador disponible.
3. Consulta al modelo de inteligencia artificial para obtener una recomendación de acción.
4. Presentación de la alerta en el cliente del SOC para su análisis.

Este modelo de funcionamiento se alinea con los principios de las plataformas SOAR (Security Orchestration, Automation and Response), cuyo objetivo es automatizar tareas repetitivas y coordinar diferentes herramientas de seguridad dentro de los centros de operaciones.

4.3 ASISTENCIA MEDIANTE INTELIGENCIA ARTIFICIAL

El sistema incorpora un modelo de Machine Learning basado en Random Forest, cuyo objetivo es apoyar al analista en la fase de respuesta ante una alerta de seguridad. A diferencia de otros sistemas orientados a la detección, el modelo no determina si un evento es malicioso, ya que se parte de que la alerta ha sido generada previamente por otros mecanismos de detección. Su función consiste en recomendar la acción más adecuada según el contexto del incidente, facilitando la toma de decisiones dentro del SOC.

Para entrenar el modelo se ha construido un dataset sintético diseñado específicamente para este trabajo, orientado a simular escenarios plausibles de operación en un Centro de Operaciones de Seguridad.

Este conjunto de datos incluye distintos tipos de alertas, niveles de severidad, características de los activos afectados y diversos factores de contexto relevantes para la gestión de incidentes.

Su generación no se realiza de forma completamente aleatoria, sino siguiendo una lógica basada en reglas y políticas de respuesta inspiradas en prácticas habituales de los SOC, lo que permite aproximar de forma razonable el proceso de toma de decisiones que tendría lugar en un entorno operativo real.

El sistema sigue además un enfoque Human-in-the-Loop, en el que la inteligencia artificial actúa como un sistema de apoyo a la decisión mientras que el analista mantiene siempre el control final sobre la respuesta al incidente.

Cuando se genera una alerta, el modelo propone una acción recomendada que se muestra al operador, quien puede evaluarla junto con el resto de información del incidente y decidir finalmente qué acción ejecutar. Junto con la predicción, el sistema proporciona también una explicación detallada que indica qué reglas o políticas del playbook del SOC han influido en la recomendación, permitiendo al analista comprender el razonamiento detrás de la decisión generada por el modelo (Manic, 2018).

Para reforzar la transparencia del sistema, se incorporan mecanismos de explicabilidad (XAI) (Adadi, 2018) accesibles desde la interfaz del SOC, como se muestra en las figuras **Figura 3**, **Figura 4** y **Figura 5** que permiten mostrar al analista qué características del incidente han tenido mayor influencia en la predicción del modelo y cómo han contribuido a la recomendación generada.

En conjunto, este enfoque permite utilizar la inteligencia artificial como una herramienta de asistencia dentro del flujo operativo del SOC, mejorando la

eficiencia en la gestión de alertas sin sustituir la supervisión humana ni perder transparencia en la toma de decisiones.

4.4 APRENDIZAJE CONTINUO Y ENTRENAMIENTO

Todas las decisiones tomadas por los analistas durante la gestión de incidentes quedan registradas en la base de datos del sistema. Este histórico de decisiones permite generar nuevos datasets que pueden utilizarse para mejorar el modelo de inteligencia artificial.

Una característica diferencial de la solución es que el reentrenamiento del modelo puede realizarse directamente desde el cliente del SOC. El operador puede seleccionar los registros que desea utilizar como dataset de entrenamiento y lanzar el proceso de reentrenamiento sin necesidad de realizar configuraciones adicionales.

El sistema gestiona automáticamente el proceso de entrenamiento y actualiza la versión del modelo utilizada en las predicciones. Este mecanismo permite adaptar el modelo a los patrones reales observados durante la operación del SOC y facilita su evolución continua.

4.5 VALOR DIFERENCIAL DE LA PROPUESTA

La principal aportación de la solución radica en la integración de automatización, inteligencia artificial explicable, supervisión humana y aprendizaje continuo dentro de un mismo entorno operativo.

A diferencia de muchas soluciones actuales que utilizan inteligencia artificial principalmente para la detección o clasificación de alertas, el sistema desarrollado integra la inteligencia artificial dentro del flujo completo de operación del SOC. Esto permite que el sistema no solo automatice tareas operativas, sino que también aprenda de la experiencia del equipo de seguridad.

Entre los elementos diferenciales del sistema destacan:

- La integración del paradigma Human-in-the-Loop en el proceso de gestión de incidentes
- La incorporación de explicabilidad (XAI) accesible desde la interfaz operativa
- La capacidad de reentrenar el modelo de manera simple desde el cliente.
- La automatización del flujo operativo mediante n8n
- La inclusión de un módulo de entrenamiento para operadores.

Esta combinación permite construir un sistema que evoluciona con el tiempo, adaptándose a la experiencia del equipo de seguridad y contribuyendo a mejorar la eficiencia y capacidad de respuesta de los centros de operaciones de seguridad.

5. DESARROLLO

5.1 CONSTRUCCIÓN DEL DATASET Y ENTRENAMIENTO DEL MODELO

El primer paso del desarrollo consistió en la construcción del dataset utilizado para entrenar el modelo de Machine Learning.

Ante la falta de datasets públicos que representaran adecuadamente el proceso de toma de decisiones en un SOC, se optó por generar uno sintético específico para este proyecto. Para ello se definieron distintas variables que describen el contexto de una alerta, como el tipo de alerta, el nivel de severidad, el tipo y criticidad del activo afectado o el contexto del incidente.

Uno de los principales retos fue evitar que el dataset estuviera completamente determinado por reglas rígidas. En un SOC real, las decisiones pueden variar según el contexto o la experiencia del analista, por lo que se introdujeron mecanismos de ruido y aleatoriedad controlada para aumentar la variabilidad de los datos y aproximar mejor un entorno real. Además, se equilibraron las clases del dataset para evitar sesgos durante el entrenamiento.

Una vez generado el dataset se evaluaron distintos algoritmos de aprendizaje supervisado. Aunque inicialmente se consideraron árboles de decisión por su simplicidad, finalmente se optó por un modelo Random Forest, al ofrecer mayor robustez, mejor capacidad de generalización y menor tendencia al sobreajuste.

5.2 SELECCIÓN DEL MODELO DE IA GENERATIVA

Además del modelo de recomendación basado en Machine Learning, el sistema incorpora un modelo de inteligencia artificial generativa destinado a integrarse en los flujos de automatización de n8n, con el objetivo de proporcionar explicaciones y asistencia contextual a los analistas durante la gestión de incidentes.

Uno de los requisitos principales fue seleccionar un modelo que pudiera utilizarse sin costes elevados y que permitiera su ejecución de forma autónoma dentro del entorno del proyecto.

Tras evaluar distintas alternativas, se optó por utilizar Ollama, una plataforma que permite ejecutar modelos de lenguaje de forma local e integrarlos fácilmente con otros servicios del sistema. En concreto, se seleccionó el modelo Llama 3.2.

Esta solución permite incorporar capacidades de generación de lenguaje natural dentro de los flujos de n8n sin depender de servicios externos ni de APIs comerciales.

5.3 CONSTRUCCIÓN DE LA ARQUITECTURA DEL SISTEMA

Una vez definidos los componentes principales se procedió a implementar los contenedores Docker que constituyen la solución.

El primer componente implementado fue la base de datos PostgreSQL, siguiendo el esquema mostrado en la Figura 2. Estructura de la base de datos. Esta actúa como repositorio central de la información generada por la plataforma, incluyendo alertas, decisiones de los analistas y datos de entrenamiento.

Posteriormente se desarrolló la API de IA, encargada de gestionar el modelo de Machine Learning. Esta API permite realizar predicciones sobre nuevas alertas y ejecutar procesos de reentrenamiento utilizando registros seleccionados por los operadores del SOC, asignando un mayor peso a estos con el objetivo de que el modelo se adapte progresivamente a la operativa real.

De forma paralela se desarrollaron el cliente del SOC y los distintos servicios de la plataforma, integrando progresivamente todos los componentes dentro del entorno basado en contenedores.

5.4 AUTOMATIZACIÓN DEL FLUJO OPERATIVO

Una vez implementados los componentes principales se integró n8n como motor de automatización encargado de orquestar los flujos operativos del SOC.

Mediante n8n se diseñaron flujos de trabajo que automatizan el ciclo de vida de las alertas de seguridad, incluyendo el registro, la asignación a operadores disponibles, la consulta al modelo de inteligencia artificial para obtener recomendaciones y la actualización del estado de los incidentes.

El desarrollo de estos flujos se realizó de forma iterativa, ampliando progresivamente las funcionalidades y optimizando su comportamiento para aproximarlos a la operativa de un SOC real.

5.5 INTEGRACIÓN DE INTELIGENCIA ARTIFICIAL EN LOS FLUJOS

Durante el desarrollo se planteó el reto de determinar en qué puntos resultaba adecuado utilizar inteligencia artificial dentro de los flujos de automatización.

Aunque estos modelos ofrecen mayor capacidad de análisis y flexibilidad, también pueden introducir errores o incrementar los tiempos de procesamiento (Rieck, 2021).

Por ello, se adoptó un enfoque híbrido en el que la inteligencia artificial se emplea únicamente en tareas donde aporta un valor claro, como la generación de explicaciones o la asistencia contextual a los analistas.

En cambio, las tareas deterministas o repetitivas se gestionan mediante scripts, reglas heurísticas o lógica condicional, garantizando así un sistema más eficiente y fiable.

6. EVALUACIÓN.

6.1 EVALUACIÓN DEL MODELO DE MACHINE LEARNING

Para evaluar el rendimiento del modelo de Machine Learning se ha utilizado un conjunto de datos de prueba independiente compuesto por 10.000 registros. El modelo seleccionado ha sido evaluado mediante métricas estándar de clasificación como accuracy, precisión, recall y F1-score. Las matrices de confusión completas pueden consultarse en las figuras **Figura 6** y **Figura 7**, donde se representa gráficamente el comportamiento del modelo para cada una de las clases.

Durante la generación del dataset se introdujeron mecanismos de variabilidad controlada, incorporando ruido en determinadas variables con el objetivo de evitar un comportamiento completamente determinista y aumentar la entropía de los datos.

A pesar de esta variabilidad introducida en el dataset, el modelo obtuvo un accuracy global del 99 %, con valores elevados de precisión y recall en todas las clases de acción evaluadas. Las métricas obtenidas fueron:

- Accuracy: 0.99
- Average F1-score: 0.987
- Weighted average F1-score: 0.990

Los resultados muestran un comportamiento consistente entre las distintas clases, con puntuaciones superiores a 0.95 en la mayoría de los casos, lo que indica que el modelo genera recomendaciones fiables para la gestión de alertas.

6.2 EVALUACIÓN DE LA AUTOMATIZACIÓN DEL FLUJO OPERATIVO

También se ha evaluado el rendimiento del sistema de automatización encargado de gestionar la asignación de alertas. Cada alerta procesada por el sistema contiene múltiples atributos de contexto relevantes, como el tipo de alerta, fase del ataque, criticidad del activo, severidad, reputación de la IP o historial de incidentes.

El flujo automatizado implementado registra la alerta y asigna automáticamente un operador disponible teniendo en cuenta el estado del sistema.

Las pruebas realizadas muestran que el tiempo medio desde la generación de una alerta hasta su asignación a un operador es de aproximadamente 15 segundos, incluyendo el procesamiento del flujo automatizado y el registro de la información en el sistema.

En un escenario sin automatización, el analista debería revisar manualmente los atributos del incidente y determinar su gestión, lo que podría requerir varios minutos de análisis. La automatización permite reducir significativamente este tiempo y agilizar la gestión inicial de alertas dentro del SOC.

6.3 EVALUACIÓN DEL FLUJO DE APRENDIZAJE

Por último, se ha evaluado el rendimiento del flujo de entrenamiento del sistema, en el que los analistas seleccionan una acción para resolver una alerta simulada y el sistema determina si la decisión tomada es correcta o no.

Durante este proceso, se registra la acción elegida, se actualizan las métricas de desempeño del usuario y, en caso de discrepancia con la recomendación del modelo, se proporciona una explicación de la acción considerada correcta.

Las pruebas realizadas indican que el tiempo medio de ejecución de este flujo es de aproximadamente 6 segundos, incluyendo el registro de la decisión del analista y la generación de la explicación correspondiente. Este tiempo de respuesta permite mantener una interacción fluida para el usuario y facilita la incorporación continua de nuevos ejemplos al sistema de aprendizaje.

6.4 COMPARACIÓN CON SOLUCIONES DEL MERCADO

Las plataformas de Security Orchestration, Automation and Response (SOAR) se utilizan ampliamente en entornos SOC para automatizar tareas repetitivas y mejorar la gestión de incidentes de seguridad.

Entre las soluciones más utilizadas en el mercado destacan herramientas como Splunk SOAR, Palo Alto Cortex XSOAR o IBM Resilient, que permiten automatizar flujos de respuesta y coordinar diferentes herramientas de seguridad dentro de un mismo entorno.

Estas plataformas se centran principalmente en la automatización de playbooks de respuesta, ejecutando acciones predefinidas ante determinados tipos de alertas. Sin embargo, en muchos casos la lógica de decisión se basa en reglas estáticas o configuraciones manuales, lo que limita su capacidad de adaptación a nuevos escenarios o a la experiencia acumulada por los analistas.

La solución propuesta en este trabajo comparte con las plataformas SOAR el objetivo de automatizar parte del flujo operativo del SOC, pero introduce algunas diferencias relevantes. En primer lugar, incorpora el modelo de Machine Learning capaz de recomendar acciones en función del contexto del incidente, en lugar de depender exclusivamente de reglas predefinidas. Además, el sistema permite reentrenar el modelo a partir de las decisiones reales tomadas por los analistas, facilitando su adaptación progresiva al entorno operativo.

Otro elemento diferencial es la incorporación del módulo de entrenamiento de analistas basado en simulación de incidentes, que permite evaluar el desempeño de los operadores y generar nuevos datos para mejorar el modelo.

En conjunto, mientras que las plataformas SOAR tradicionales se centran en la automatización de tareas operativas, la solución desarrollada integra automatización, recomendación basada en inteligencia artificial y aprendizaje continuo, permitiendo evolucionar el sistema a partir de la experiencia acumulada en el SOC.

7. CONCLUSIÓN

Este trabajo ha permitido analizar el potencial de la inteligencia artificial como apoyo en la operación de un Centro de Operaciones de Seguridad, a través del diseño y desarrollo de un prototipo parcialmente autogestionado mediante IA. La solución desarrollada integra automatización, modelos de Machine Learning y mecanismos de monitorización dentro de un entorno unificado que reproduce el flujo operativo de un SOC, permitiendo evaluar cómo estas tecnologías pueden contribuir a mejorar la gestión de alertas y la toma de decisiones de los analistas.

Uno de los principales aprendizajes del proyecto ha sido comprobar que la inteligencia artificial resulta especialmente útil cuando se integra como sistema de apoyo dentro del proceso operativo, en lugar de sustituir al analista.

El enfoque Human-in-the-Loop adoptado permite combinar las recomendaciones del modelo con la supervisión humana, manteniendo el control final de la decisión en el operador y favoreciendo la transparencia en el proceso de gestión de incidentes.

Los resultados obtenidos muestran que la automatización del flujo mediante n8n permite reducir significativamente los tiempos de gestión inicial de las alertas, facilitando su registro, asignación y análisis dentro del sistema. Por otro lado, el modelo de Machine Learning basado en Random Forest ha obtenido métricas elevadas en el conjunto de pruebas utilizado, lo que indica que puede generar recomendaciones coherentes dentro del contexto del dataset generado.

No obstante, durante el desarrollo también se han identificado varias limitaciones. Una de las principales está relacionada con el rendimiento de algunos modelos utilizados dentro del sistema, especialmente en el caso de los modelos generativos ejecutados localmente.

Aunque soluciones como Ollama permiten una integración sencilla y sin costes adicionales, su rendimiento y calidad de respuesta son inferiores a los de modelos comerciales de mayor capacidad. Es razonable considerar que el uso de modelos de pago o infraestructuras más potentes podría mejorar significativamente la calidad de las explicaciones generadas y la asistencia proporcionada a los analistas.

Como trabajo futuro, una de las líneas más relevantes sería sustituir el simulador de alertas por una entrada real de eventos procedentes de herramientas de seguridad, lo que permitiría evaluar el comportamiento del sistema en un entorno más cercano a la operación real de un SOC.

También resultaría interesante analizar la escalabilidad de la solución mediante pruebas de estrés con múltiples operadores trabajando simultáneamente, con el objetivo de evaluar el rendimiento del sistema bajo cargas elevadas. Igualmente, podría explorarse la integración con herramientas SIEM o EDR reales y la experimentación con modelos de inteligencia artificial más avanzados para mejorar las capacidades de recomendación y análisis del sistema.

8. BIBLIOGRAFIA

- Adadi, A. a. (2018). Peeking Inside the Black-Box: A Survey on Explainable Artificial Intelligence (XAI). *IEEE Access*, 52138-52160. doi:10.1109/ACCESS.2018.2870052
- Apruzzese, G. a. (2023). The Role of Machine Learning in Cybersecurity. *Digital Threats: Research and Practice*, 1–38. doi:10.48550/arXiv.2206.09707
- Buczak, A. L. (2016). A Survey of Data Mining and Machine Learning Methods for Cyber Security Intrusion Detection. *IEEE Communications Surveys & Tutorials*, 1153-1176. doi:10.1109/COMST.2015.2494502
- Manic, D. L. (2018). An Adversarial Approach for Explainable AI in Intrusion Detection Systems. *IEEE Access*, *. doi:10.1109/IECON.2018.8591457
- Rieck, D. A. (2021). Dos and Don'ts of Machine Learning in Computer Security. *IEEE Access*, *. doi:10.48550/arXiv.2010.09470
- Shaukat, K. a. (2020). A Survey on Machine Learning Techniques for Cyber Security in the Last Decade. *IEEE Access*, *. doi:10.1109/ACCESS.2020.3041951
- Xin, Y. a. (2018). Machine Learning and Deep Learning Methods for Cybersecurity. *IEEE Access*, 1-1. doi:10.1109/ACCESS.2018.2836950

9. ANEXOS

9.1 CÓDIGO FUENTE DE LA SOLUCIÓN

El código fuente del sistema desarrollado se encuentra disponible en el repositorio público del proyecto en GitHub:

<https://github.com/pablonoriega/IA-Runned-Soc>

9.1 DIAGRAMA DE ARQUITECTURA DE LA SOLUCIÓN




Figura 1. Arquitectura de la solución SOC.

9.2 ESTRUCTURA DE LA BASE DE DATOS.




Figura 2. Estructura de la base de datos

9.3 CLIENTE SOC

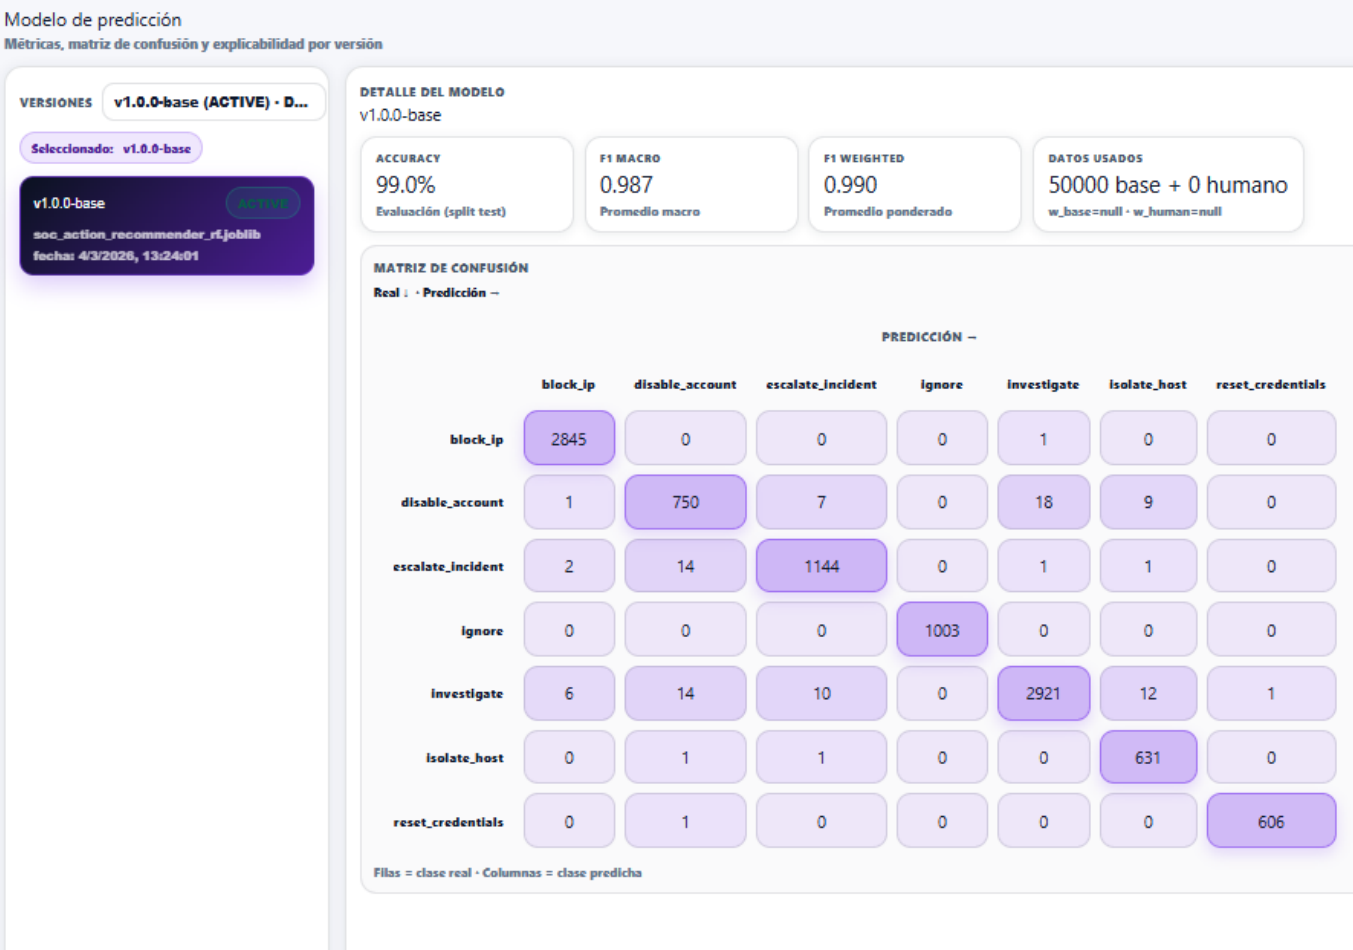


Figura 3. Matriz de confusión mostrada en el cliente SOC.

TOP FEATURES · PERMUTATION		
#	Feature	Importance
1	severity	0.358860
2	attack_phase	0.236140
3	asset_criticality	0.231100
4	repeat_offender	0.187100
5	alert_type	0.155820
6	event_count	0.073760
7	asset_type	0.067380
8	event_rate	0.034360
9	downtime_tolerance	0.028720
10	user_role	0.014780
11	confidence	0.012080
12	isolation_supported	0.011740
13	asset_exposure	0.002740
14	time_window_minutes	0.002360
15	ip_reputation	0.001700
16	is_privileged_account	0.001380
17	geo_anomaly	0.000280
18	src_ip_is_private	0.000100
19	dayofweek_utc	0.000080
20	src_country	0.000060

Figura 4. Contribución de las características en la predicción del modelo mostrada en el cliente SOC.

MÉTRICAS POR CLASE				
Clase	Precision	Recall	F1	Support
ignore	1.000	1.000	1.000	1003
block_ip	0.997	1.000	0.998	2846
investigate	0.993	0.985	0.989	2964
isolate_host	0.966	0.997	0.981	633
disable_account	0.962	0.955	0.958	785
escalate_incident	0.985	0.985	0.985	1162
reset_credentials	0.998	0.998	0.998	607

dataset_ref: train\soc_dataset.csv
computed: 4/3/2024, 13:24:01

Figura 5. Métricas por clase mostradas en el cliente SOC

9.4 RESULTADOS DEL ENTRENAMIENTO DEL MODELO




Figura 6. Matriz de confusión normalizada




Figura 7. Matriz de confusión